

TÉCNICAS DE INTELIGENCIA ARTIFICIAL

TEMA 2 - REGRESIÓN LINEAL

EJERCICIOS

CONCEPTUALES

EJERCICIO 1

Describe la hipótesis nula a la cual corresponden los p-valores de la tabla abajo mostrada. Explica que conclusiones pueden obtenerse en base a esos p-valores. La explicación debe darse en términos de **sales**, **TV**, **radio**, y **newspaper**, en lugar de en términos de coeficientes del modelo lineal.

	Coeficiente	Error estándar	Estadístico t	p-valor
Intercepto	2.939	0.3119	9.42	< 0,0001
TV	0.046	0.0014	32.81	< 0,0001
radio	0.189	0.0086	21.89	< 0,0001
newspaper	-0.001	0.0059	-0.18	0.8599

EJERCICIO 2

Supongamos que tenemos un conjunto de datos con 5 predictores: X_1 = NM (nota media), X_2 = CI (cociente intelectual), X_3 = Género (1 para mujer y 0 para hombre), X_4 = término de interacción entre NM y CI y X_5 = término de interacción entre NM y Género. La respuesta, Y , es el salario inicial justo después de graduarse (en millares de dólares). Supongamos que usamos mínimos cuadrados para ajustar un modelo, y obtenemos $\hat{\beta}_0 = 50$, $\hat{\beta}_1 = 20$, $\hat{\beta}_2 = 0,07$, $\hat{\beta}_3 = 35$, $\hat{\beta}_4 = 0,01$ y $\hat{\beta}_5 = -10$.

1. ¿Qué respuesta es correcta? ¿Por qué?
 - a) Para un valor fijo de CI y NM, de media los hombres ganan más que las mujeres.
 - b) Para un valor fijo de CI y NM, de media las mujeres ganan más que los hombres.
 - c) Para un valor fijo de CI y NM, de media los hombres ganan más que las mujeres siempre y cuando NM es lo suficientemente alta.
 - d) Para un valor fijo de CI y NM, de media las mujeres ganan más que los hombres siempre y cuando NM es lo suficientemente alta.
2. Predecir el salario de un mujer con un CI de 110 y una NM de 4.0.
3. Verdadero o falso: dado que el coeficiente de la interacción entre NM y CI es muy pequeño, hay poca evidencia de que haya un efecto de interacción. Justifica la respuesta.

EJERCICIO 3

Recopilamos una base de datos ($n = 100$ observaciones) que contiene un único predictor y una respuesta cuantitativa. Ajustamos un modelo de regresión lineal a los datos, y por otro lado, un modelo de regresión cúbico, es decir, $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$

1. Supongamos que la verdadera relación entre X e Y es lineal, es decir, $Y = \beta_0 + \beta_1 X + \epsilon$. Consideramos la suma cuadrática de residuos (RSS) en entrenamiento para la regresión lineal, y también para la RSS de entrenamiento para la regresión cúbica. ¿Esperamos que una se menor que la otra, que sean iguales, o no tenemos suficiente información para decidir? Justifica la respuesta.
2. Responder la pregunta anterior, pero esta vez considerando la RSS de test en lugar de la RSS de entrenamiento.
3. Supongamos que la verdadera relación entre X e Y es no-lineal, pero no sabemos cómo de lejos está de la lineal. Consideramos la suma cuadrática de residuos (RSS) en entrenamiento para la regresión lineal, y también para la RSS de entrenamiento para la regresión cúbica. ¿Esperamos que una se menor que la otra, que sean iguales, o no tenemos suficiente información para decidir? Justifica la respuesta.
4. Responder la pregunta anterior, pero esta vez considerando la RSS de test en lugar de la RSS de entrenamiento.

EJERCICIO 4

Haciendo uso de las siguientes ecuaciones que usamos en el caso regresión lineal simple:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

demostrar que la línea de mínimos cuadrados pasa por el punto $(\bar{x}, \bar{y})$.

EJERCICIO 5

En clase hemos comentado que en el caso de regresión lineal simple el estadístico R^2 es igual al cuadrado de la correlación entre X e Y . Realiza la demostración.

APLICADOS

EJERCICIO 6

Este ejercicio está relacionado con el uso de la regresión lineal simple en la base de datos

Auto:

1. Ajustar un modelo de regresión lineal simple que tenga **mpg** como respuesta y **horsepower** como predictor. Responde a las siguientes preguntas:
 - a) ¿Existe relación entre predictor y respuesta?
 - b) ¿Cómo de fuerte es la relación entre predictor y respuesta?
 - c) ¿Es la relación entre predictor y respuesta negativa o positiva?
 - d) ¿Cuál es el **mpg** estimado para un **horsepower** igual a 98? ¿Cuáles son los intervalos de confianza y predicción del 95 %?
2. Visualiza gráficamente predictor vs respuesta, y la recta de regresión.
3. Visualiza gráficas de residuos y de influencia (*leverage*) y comenta los posibles problemas que existan con el ajuste por mínimos cuadrados.

EJERCICIO 7

Este ejercicio implica el uso de la regresión lineal múltiple en la base de datos **Auto:**

1. Producir una matriz con las diferentes gráficas de dispersión (*scatterplots*) para las diferentes variables de la base de datos.
2. Calcular la matriz de correlación entre las diferentes variables. Únicamente excluir la variable **name**, única no numérica.
3. Ajustar un modelo de regresión lineal múltiple que tenga **mpg** como respuesta y el resto de variables, excepto **name**, como predictores. Responde a las siguientes preguntas:
 - a) ¿Existe relación entre predictores y respuesta?
 - b) ¿Qué predictores parecen tener una relación estadísticamente significativa con la respuesta?
 - c) ¿Qué sugiere el coeficiente de la variable **year**?
4. Visualiza gráficas de residuos y de influencia (*leverage*) y comenta los posibles problemas que existan con el ajuste por mínimos cuadrados. ¿Los gráficos de residuos sugieren la presencia de valores atípicos inusualmente grandes? ¿El gráfico de influencia sugiere la presencia de observaciones con influencia (*leverage*) inusualmente alta?
5. Introduce términos de interacción en el modelo. ¿Es posible que algún término de interacción sea estadísticamente significativo?

6. Prueba diferentes transformaciones de las variables como por ejemplo $\log(X)$, $\sqrt{X}$ o X^2 . Comenta los resultados.
-

EJERCICIO 8

Este ejercicio implica el uso de la regresión lineal múltiple en la base de datos **Carseats**:

1. Ajustar un modelo de regresión lineal múltiple para predecir **Sales** en función de **Price**, **Urban** y **US**.
 2. Interpreta cada coeficiente de regresión del modelo. Ten en cuenta que algunas variables incorporadas en el modelo son cualitativas.
 3. ¿Para qué predictores se puede rechazar la hipótesis nula $H_0 : \beta_j = 0$?
 4. En base a la respuesta del apartado anterior, ajusta un modelo con menos predictores que únicamente use predictores para los cuales existe evidencia de asociación con la respuesta.
 5. ¿Cómo de bien se ajustan los modelos de los apartados 1 y 4?
 6. Usando el modelo del apartado 4, obtener los intervalos de confianza del 95 % para los coeficientes de regresión.
 7. ¿Existe presencia de observaciones con valores atípicos o con influencia (*leverage*) inusualmente alta?
-